Large-scale inference and learning algorithm

Jean-Christophe Janodet
University of Evry, France

Objectifs

- Revoir la théorie des langages formels :
  - Automates, CFG, transducteurs, HMM, …
  - Formalismes probabilistes ou non : WFSM / WFST
  - Relations entre ces formalismes
- Etudier les principaux algorithmes exploitant ces machines : parsing, inference, équivalence, apprentissage
- Applications en Traitement de la langue

Prisme : Inférence grammaticale

- Ce que ça permet :
  - Apprentissage à partir de données structurées :
    - mots, arbres, graphes, etc.
  - Recherche d'une hypothèse *cible* particulière :
    - automate, grammaire, standard ou stochastique
- Ce que ça ne permet pas (directement) :
  - problèmes de classification
  - problèmes de classement

La communauté en IG

- International Community in Grammatical Inference (ICGI)
- Communauté hétéroclite, avec des chercheurs travaillant en
  - Pattern recognition, Machine learning, Computational linguistics (or not), Bioinformatics
  - Algorithmics, Language theory, Information theory
- Géographie de la communauté :
  - Japan, Spain, Germany, Great Britain, Belgium, The Netherlands, USA, Australia, France

Principaux événements

- The International *Colloquium* in Grammatical Inference (ICGI) tous les 2 ans depuis 1994
- Workshops + écoles en alternance à ECML, NIPS, IJCAI
- Compétitions d'algorithmes :
  - Abbadingo (1998), Omphalos (2004)
  - Gecco (2004), Tenjinno (2006)
  - Zulu (2010), Stamina (2010)

Surveys et livres

- Surveys:
  - D. Angluin & C. Smith. *Inductive inference: Theory and pratice.* ACM computing surveys, 15(3):237-269, 1983
  - L. Miclet. *Syntactic and structural pattern recognition.* Chap. GI, 237-290. World Scientific, 1990
  - Y. Sakakibara. *Recent advances of GI.* Theoretical Computer Science, 185:15-45, 1997
- Book:
  - C. de la Higuera. *GI: Learning automata & grammars.* Cambridge University Press, 2010.

Caractéristiques d'un problème d'Inférence Grammaticale

- Ce que ça permet :
  - Apprentissage à partir de données structurées :
    - mots, arbres, graphes, etc.
  - Recherche d'une hypothèse *cible* particulière :
    - automate, grammaire, standard ou stochastique
- Ce que ça ne permet pas (directement) :
  - problèmes de classification
  - problèmes de classement

Exemple 1
Modélisation des systèmes

- Contexte :
  - Réingénierie : reconstruction de la spécification d'un système, « exploration » d'un site web
  - Certification : preuve du bon fonctionnement d'un système critique
  - Débogage, tests logiciels, tests matériels
- Réalisation :
  - Modélisation sous la forme d'automates de Mealy, d'automates IO, d'automates d'interfaces, *etc*

Exemple 2
Natural Language Processing

- Contexte :
  - Modèle de langage attribuant une probabilité à toute phrase, correcte ou non
  - Traduction automatique, attribuant une probabilité à toute traduction, correcte ou non
- Réalisation :
  - Automate stochastique, grammaire probabiliste (PCFG), modèle de Markov (HMM), transducteur (stochastique)

Cas général (1)

- On dispose d'une classe de grammaires :
  - de mots : AFD, AFN, AFER, automates de Moore, de Mealy, GHC, GHC linéaires déterministes, SRM, motifs, boules, expression régulière, …
  - d'arbres, de graphes, de termes , …
- Grammaire = tout périphérique permettant de reconnaître / engendrer / décrire un langage
- Deux versions : standard *vs* stochastique

Cas général (2)

- Une des grammaires est sélectionnée : la grammaire *cible*, celle que cherche l'apprenant
- Le mode d'acquisition des données est fixé par l'application :
  - Elles peuvent être positives seulement, ou positives et négatives
  - Elles peuvent être subies (apprentissage passif) ou choisies (apprentissage actif)

Cas général (3)

- Ce qu'« apprendre » veut dire est fixé, i.e., un paradigme d'apprentissage est donné :
  - Identification exacte :
    - Données subies : Identification à la limite (Gold 67, 78)
    - Données choisies : Query learning (Angluin 87)
  - Identification approximative :
    - Données subies : PAC-leaning (Valiant 84)
    - Données choisies : active learning

1er cas : Query learning

- D. Angluin. *Learning regular sets from queries and counterexamples.* Inform. and Computat. 75:87-106, 1987
- Cadre : identification exacte, données choisies
- Problème : deviner un DFA en posant des questions (requêtes) à un professeur
- Applications actuelles :
- Tests de protocoles de sécurité ou de comm. (Shu & Lee 2007, Aarts et al 2014), détection de failles de sécurité dans les sites web (Hossen et al 2014)
- Formalisation des langues rares (…)

Mots

- Un *alphabet* Σ est un ensemble fini non vide de symboles qu'on appelle *lettres*. *E.g.*, $\Sigma=\{0,1\}$.
- Un *mot* w sur Σ est une séquence finie de lettres. E.g., 0, 1, 00, 10, 11010, λ, …
- Notations:
  - |w| : longueur du mot w
  - uv : concaténation des mots u et v
  - Σ^* dénote l'ensemble de tous les mots

Langages

- Un langage est une sous-ensemble de Σ^*
- Hiérarchie de Chomsky :
  - Couche 4: Langages finis
  - Couche 3: Langages réguliers
  - Couche 2: Langages hors-contextes
  - Couche 1: Langages sous-contextes
  - Couche 0: Langages récursivement énumérables
- De nombreux langages n'entrent pas dans cette hiérarchie (e.g., *pattern languages, multiple CFL*)

Langages réguliers (1)

- Réguliers = rationnels = reconnaissables = reconnus par des automates
- Un AFD est un tuple $A=<Q, \Sigma, i, F, \delta>$ t.q.
  - Q : ensemble fini d'états
  - Σ : alphabet d'entrée
  - i : état initial
  - F : ensemble des états acceptants
  - δ : $Q \times \Sigma \rightarrow Q$: fonction de transition

Langages réguliers (2)

- Taille de A = |Q| = nombre d'états
- Parsing : linéaire en |w|
- Equivalence : $O(n_1 \log n_1 + n_2 \log n_2)$
- Propriétés « jolies », beaucoup d'algorithmes :
  - Déterminisation des AFN
  - Minimisation des AFD

Paradigme d'Angluin

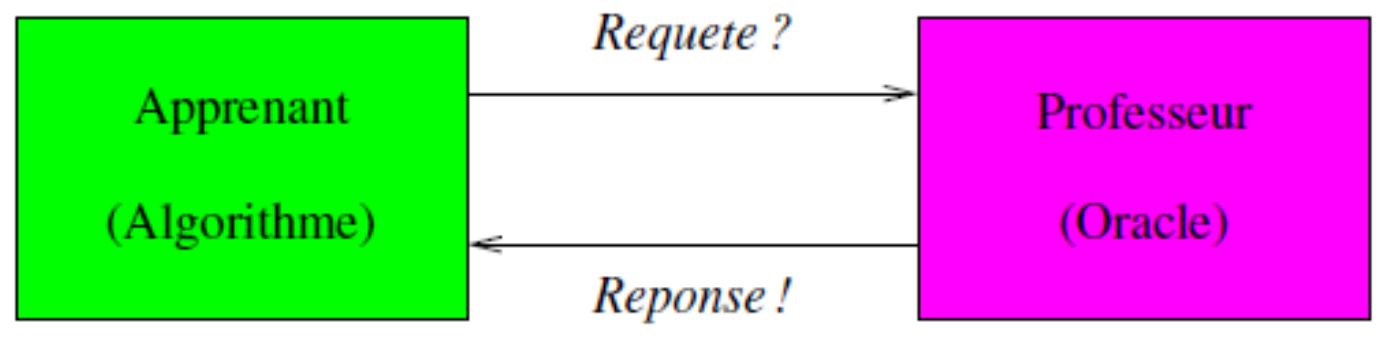

- Contexte :
  - L'oracle choisit un DFA, l'apprenant doit le trouver
- Règles :
  - L'apprenant pose des questions (requêtes) à l'Oracle
  - L'Oracle répond sans mentir
  - Le type de requêtes est fixé : appartenance, équivalence, . . .

Résultats

- Les AFD sont identifiables en temps polynomial à partir de requêtes d'appartenance et d'équivalence
- … « polynomial » en :
  - la taille de l'AFD cible
  - la longueur du plus long contre-exemple
- L* : algorithme de référence aujourd'hui
- Extensions théoriques aux GHC

2nd cas : appr. passif des AFD

- Exemple : On considère E_+ = { λ , 1, 01, 011, 101 } et E_- = { 00, 10}.
- Problème : apprendre un AFD compatible avec les données, i.e., qui accepte tous les mots de E_+ et rejette tous ceux de E_-

Problème mal formulé

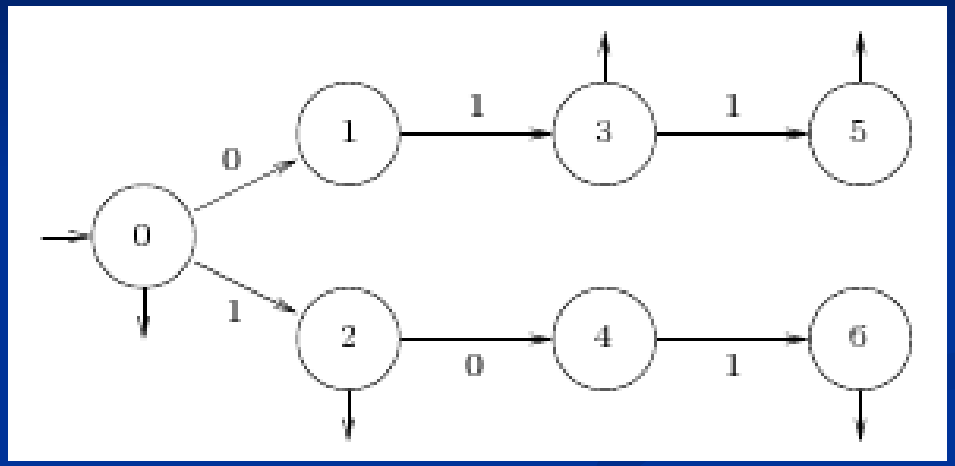

- On calcule le PTA de $E_+ = \{ \lambda, 1, 01, 011, 101 \}$
- Problème pas très intéressant …

Problème trop difficile

- Problème : on cherche le *plus petit* AFD compatible avec les données

- Théorème [Gold 78] :

  Le problème suivant est NP-complet :

  - Données : 1 entier N, 2 ensembles E_+ et E_- de mots
  - Problème : Existe-t'il un AFD de moins de N états reconnaissant tous les mots de E_+ et aucun de E_- ?

Biais inductif

- On suppose que les données *caractérisent* la cible :
  - Les mots de E_+ exercent tous les états, tous les états finaux, et toutes les transitions de l'AFD cible
  - Les mots de E_+ et E_- permettent de distinguer deux états qui sont différents
- Déf. formelle : cf (de la Higuera '10)

RPNI (Oncina ' 92)

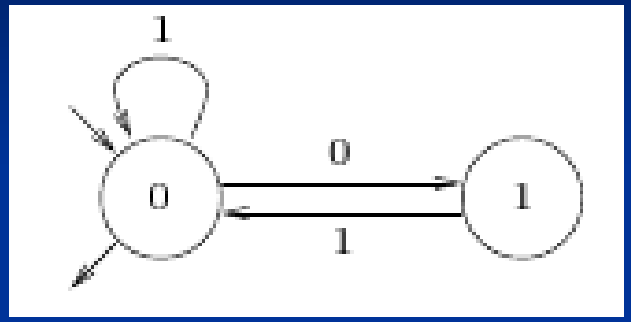

- On considère la cible précédente et l'échantillon $E_+ = \{ \lambda, 1, 01, 011, 101 \}$ et $E_- = \{ 00, 10 \}$.

Prefix Tree Acceptor

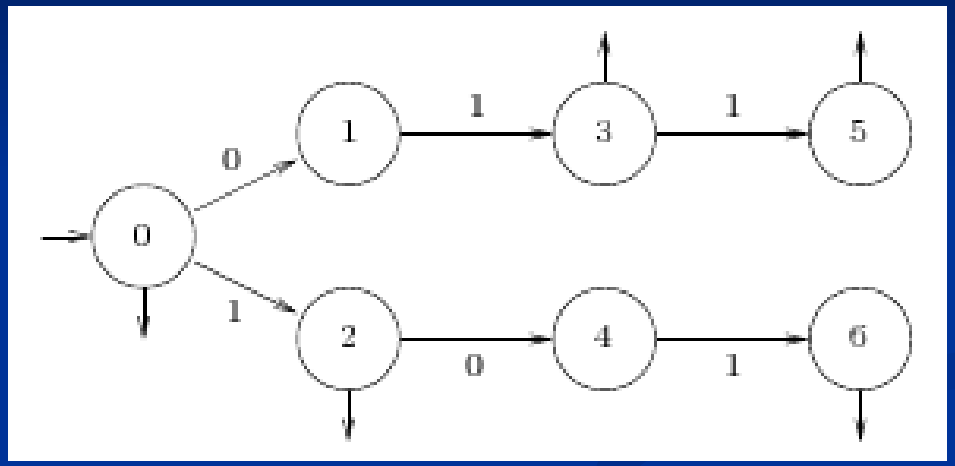

- On calcule le PTA de $E_+ = \{ \lambda, 1, 01, 011, 101 \}$

1ère fusion (de 1 et 0)

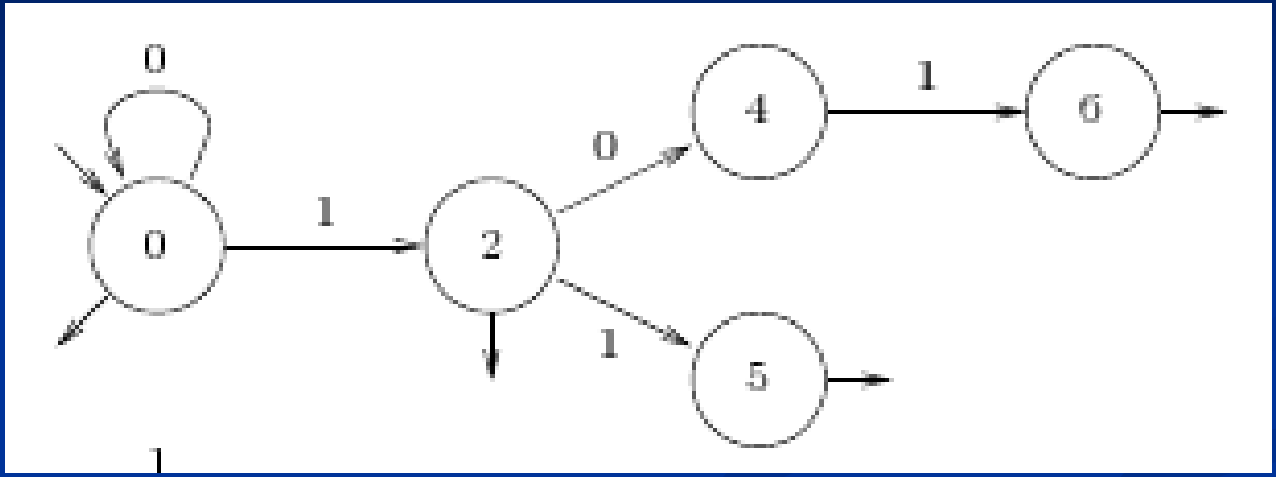

- On a E_ = { 00, 10 } et 00 est reconnu
- La fusion est rejetée

2nde fusion (de 2 et 0)

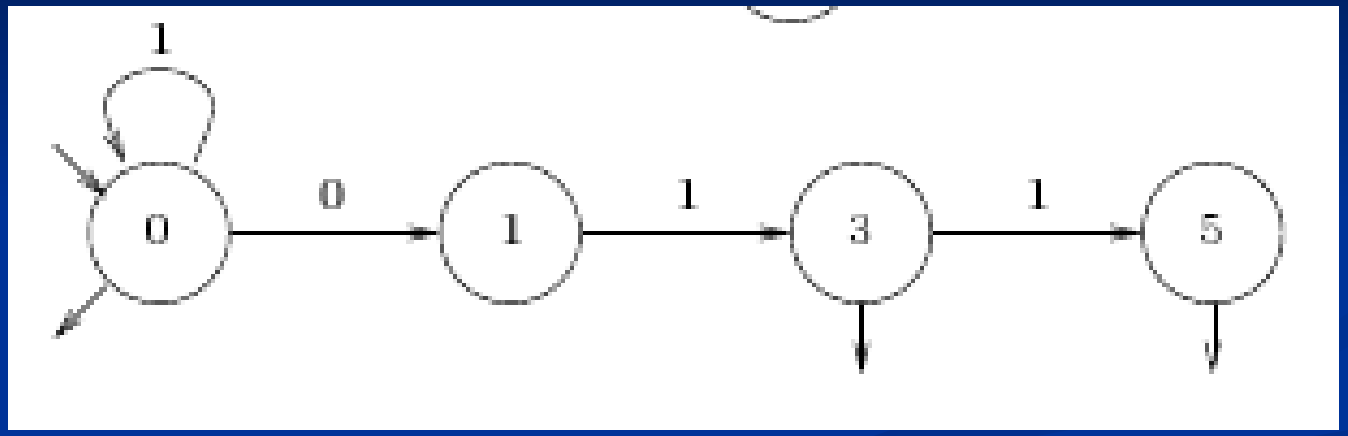

- On a E_ = { 00, 10 }, pas d'inconsistance
- La fusion est acceptée

3ème fusion (de 3 et 0)

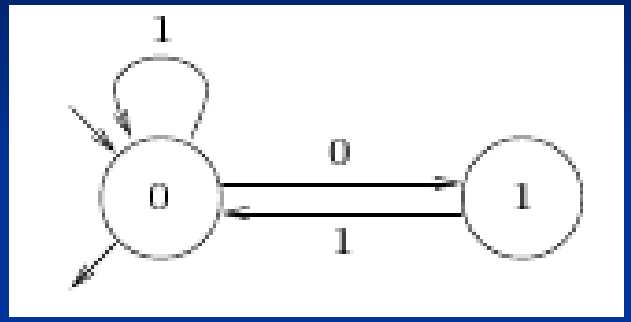

- On a E_ = { 00, 10 }, pas d'inconsistance
- La fusion est acceptée
- Miracle : c'est la cible

Propriétés de RPNI

- Théorème :
  - L'AFD retourné par RPNI est toujours consistant avec l'échantillon initial
  - Chaque AFD admet au moins un échantillon caractéristique de taille polynomial qui, s'il est inclus dans l'échantillon d'apprentissage, fait converger RPNI vers l'AFD minimal équivalent.

Extensions de RPNI

- Approches *data-driven* : EDSM :
  - L'ordre des fusions d'états dépend de statistiques sur les données (*ie*, on favorise les fusions les plus sures)
  - Arbitrairement mauvais sur un plan théorique, mais pas sur un plan pratique …
- Extensions aux transducteurs de mots, aux automates d'arbres, *etc.*

3ème cas : appr. passif des GHC

- Pb. beaucoup plus difficile que pour le AFD
  - Dans le cas des AFD, relation profonde entre les données (mots) et les états de l'AFD (notion de résiduel), mais rien de ce genre pour les règles d'une grammaire : les données ne nous apportent pas d'info. sur la structure de la GHC cible
  - Exemples positifs uniquement

Langages hors-contextes (1)

- Engendrés par des GHC
- Une GHC est un tuple $G=<\Sigma, V, P, S>$ t.q.
  - Σ : alphabet d'entrée
  - V : alphabet non terminal
  - P : ensemble des productions de la forme $X \rightarrow w$, où w est un mot de $(\Sigma \cup V)^*$
  - S : symbole *start*

Langages hors-contextes (2)

- Parsing : $O(\|G\| |w|^3)$:
  - Passage à la forme normale de Chomsky
  - Algo. CYK par programmation dynamique
- Equivalence : indécidable
- Nombreuses « mauvaises » propriétés :
  - problèmes d'ambiguité, de déterminisme
  - problèmes de non linéarité
  - problèmes de clôture

Lien données / GHC (Clark '07)

- Congruence syntaxique : soit L un langage ;

  $u \approx v$ *si pour tous mots* l,r , ($lur \in L$ *ssi* $lvr \in L$)

- Intuition : deux mots équivalents sont générés par le même non terminal (Harris '57)
- « Congruence » faible : soit L un langage ;

  $u \sim v$ *si il existe* l,r , ($lur \in L$ *ssi* $lvr \in L$)

- L est substituable si pour tout mot u, v

  si $u \sim v$ *alors* $u \approx v$

Algorithme SGL (Clark '07) (1)

- On suppose que le langage cible est substituable
- On a un échantillon positif de mots E_+
- On construit un graphe :
  - Nœuds : facteurs des mots de E_+
  - Arêtes : u et v sont liés si $u \sim v$, ie, ils apparaissent dans le même contexte

Algorithme SGL (2)

- Construction de la grammaire :
  - Non terminaux : composante connexe du graphe
  - Starter : composante contenant tous les mots de E_+
  - Règles :
    - $[\![a]\!] \to a$ pour toute lettre a
    - $[\![uv]\!] \to [\![u]\!]\ [\![v]\!]$ pour tout facteur uv de longueur $\geqslant 2$
    - $[\![u]\!] \to [\![v]\!]$ pour tout $u \sim v$